Mogu li lokalni jezički modeli da pišu Lean 4 dokaze?

Mileta Avramović, Petar Maletin

Sažetak

Veliki jezički modeli ubedljivo pišu matematički tekst, ali ubedljivost nije dokaz ispravnosti. U ovom radu presudu o svakom dokazu donosi interaktivni dokazivač teorema Lean 4 [1] sa bibliotekom Mathlib [2]. Dokaz se prihvata isključivo ako ga kompajler prihvati. Evaluiramo osam malih, lokalno pokrenutih modela, kroz Ollama [3] alat, na dve elementarne teoreme o sabiranju prirodnih brojeva, kroz jednokratni i agentni protokol, petlja popravke alata Ulam AI [4], pri čemu je svih osam modela evaluirano u oba protokola. Pod fiksiranim alatima (Lean 4.31.0, Mathlib v4.31.0) uspešno se kompajlira 7 od 16 jednokratnih dokaza (43,75 %) i 14 od 48 agentnih pokušaja, čime je rešeno 7 od 16 parova modela i teoreme. Svaki uspešan dokaz poziva jednu gotovu lemu iz Mathlib-a, dok nijedan pokušaj indukcije nije preživeo kompajliranje. Jedini model sa maksimalnim učinkom u oba protokola je GLM-4.7-Flash, mešavina eksperata sa režimom rezonovanja. Agentna petlja izraženo pomaže modelima za kod, DeepSeek-R1 jednokratno ne rešava asocijativnost, a agentno je rešava u sva tri pokušaja, ali uz visoku vremensku cenu. Rezultati pokazuju da na ovom zadatku nije presudna veličina modela već podaci na kojima je treniran.

1 Uvod

Kada jezički model napiše dokaz, postavlja se pitanje ko taj dokaz proverava. Ako je proveravač čovek, greške modela su upravo one koje se najteže uočavaju, jer su tečno napisane; ako je proveravač drugi model, poverenje se samo premešta. Zato se oslanjamo na treći odgovor a to je formalni dokazivač teorema. U sistemu Lean 4 [1] dokaz je program koji proverava malo, strogo provereno jezgro, pa pitanje „da li je dokaz ispravan“ postaje pitanje „da li se datoteka kompajlira“. Ako se datoteka kompajlira bez greške, dokaz je ispravan; ako se ne kompajlira, dokaza nema.

Postavljamo pitanje: mogu li mali, besplatni jezički modeli, pokrenuti lokalno kroz alat Ollama [3], da napišu Lean 4 dokaze koji se zaista kompajliraju? Zadatak su dve elementarne teoreme o sabiranju prirodnih brojeva:

- Teorema A (asocijativnost): $(a + b) + c = a + (b + c)$
- Teorema B (komutativnost): $a + b = b + a$.

Povezivanje jezičkih modela sa dokazivačima razvijena je oblast: LeanDojo omogućava programski pristup stanju dokaza i izvršavanje taktika [5], a skup miniF2F postavlja standard za poređenje na takmičarskim zadacima [6]. Učenje potkrepljivanjem sa proverljivim nagradama (GRPO u sistemu DeepSeekMath [7], DeepSeek-R1 [8], Tülü 3 [9]) počiva na signalu koji se može mehanički proveriti; kompajler dokazivača daje najstrožiji takav signal, upravo onaj kojim mi merimo. Testirani modeli potiču iz familija Gemma [10] i GLM [11]; za skupo rezonovanje relevantna je i kompresija modela tipa mešavine eksperata [12], kojoj pripada naš najuspešniji model.

Svaki generisani dokaz kompajlira se komandom `lake env lean` pod fiksiranim alatima Lean 4.31.0 i Mathlib v4.31.0. Dokaz se računa kao **uspeh** samo ako: (1) nema `sorry` ni `admit`; (2) zadržava tačan iskaz teoreme; (3) kompajlira se bez ijedne greške. Vremensko ograničenje tipske provere postavljeno je na 300 s, kako učitavanje Mathlib-a pod pritiskom memorije ne bi lažno obaralo ispravne dokaze.

Modeli su generisani i verifikovani na dve mašine, pri čemu je svaki model verifikovan pod istim fiksiranim alatima, pa su presude uporedive. Familije Gemma i GLM rađene su na Mac mini računaru, a familije Qwen i DeepSeek na MacBook Pro računaru.

Modeli	**Mašina**	**Čip**	**RAM**
Gemma 3 i GLM (jednokratno i agentno)	Mac mini	Apple M4	24 GB
Qwen i DeepSeek (jednokratno i agentno)	MacBook Pro 16”	Apple M2 Max	32 GB

Svih osam modela evaluirano je u oba protokola: Jednokratni protokol znači da se model pita jednom i da se njegov odgovor kompajlira. Agentni protokol, koji sprovodi alat Ulam AI [4], zamenjuje jedno pitanje petljom popravke: model napiše dokaz, Lean ga kompajlira, greška kompajlera se vraća modelu kao ulaz i model pokušava ponovo, najviše četiri puta unutar jednog pokušaja (opcija `-llm-rounds 4`), pri čemu petlja staje ranije ako model ponavlja isti odgovor (stagnacija). Pošto Ulam AI uzorkuje na podrazumevanoj, nenultoj temperaturi, ishod jednog pokušaja je slučajan, pa je cela komanda `ulam prove` pokrenuta tri puta po svakoj kombinaciji modela i teoreme; oznake 3/3, 1/3 i 0/3 u tabelama govore koliko se od ta tri nezavisna pokušaja uspešno kompajliralo. Oznaka 0/3 tako znači da model ni u jednom od tri pokušaja, od kojih je svaki imao najviše četiri runde popravke, nije proizveo dokaz koji se kompajlira; u praksi model tada obično ponavlja istu grešku, pa se petlja zaustavlja zbog stagnacije.

2 Rezultati

Oznaka **uspeh** znači da se dokaz uspešno kompajlira (dokazano), a neuspeh da se ne kompajlira. Agentne kolone pokazuju koliko je od 3 nezavisna pokušaja uspelo.

Model	Familija	Param.	Računar	asoc.	kom.	ag. asoc.	ag. kom.
GLM-4.7-Flash	GLM (MoE)	29,9B	Mac mini	**uspeh**	**uspeh**	3/3	3/3
GLM-4 9B	GLM	9,4B	Mac mini	neuspeh	**uspeh**	0/3	0/3
Gemma 3 12B	Gemma 3	12,2B	Mac mini	neuspeh	neuspeh	0/3	0/3
Gemma 3 4B	Gemma 3	4,3B	Mac mini	neuspeh	neuspeh	0/3	1/3
Qwen2.5-Coder 14B	Qwen	14B	MacBook Pro	**uspeh**	neuspeh	2/3	1/3
Qwen3	Qwen	8B	MacBook Pro	**uspeh**	neuspeh	1/3	0/3
DeepSeek-Coder-V2 16B	DeepSeek	16B	MacBook Pro	**uspeh**	**uspeh**	0/3	0/3
DeepSeek-R1 8B	DeepSeek	8B	MacBook Pro	neuspeh	neuspeh	3/3	0/3

Ukupno (jednokratno) uspešno se kompajlira 7 od 16 dokaza (43,75 %): asocijativnost 4/8, komutativnost 3/8.
Agentno uspešno se kompajliralo 14 od 48 pokušaja, rešeno je 7 od 16 parova modela i teoreme u bar jednom od tri pokušaja.

Jednokratni protokol za DeepSeek-Coder-V2 16B daje jednoredne dokaze (`rw [Nat.add_assoc]`, `rw [Nat.add_comm]`) koji se uspešno kompajliraju, pa model ostvaruje **uspeh** na obe teoreme. DeepSeek-R1 8B jednokratno ne rešava nijednu teoremu: na asocijativnosti piše neispravnu ugnježdenu indukciju, a na komutativnosti posle 737,7 s generisanja ne proizvodi iskoristiv izlaz. Agentno, međutim, isti model rešava asocijativnost u sva tri pokušaja.

Tabela 1 daje trajanja generisanja. Ističe se DeepSeek-R1 kao model sa rezonovanjem, već jednokratno na komutativnosti troši 737,7 s, a agentno između 1.712 s i 2.150 s po pokušaju, pri čemu je svaki od tih pokušaja neuspešan.

Verifikacija jedne datoteke traje od 15 do 30 s (učitavanje Mathlib-a), a duže pod pritiskom memorije.

Tabela 2 sabira trajanja svih pokušaja po mašini, pri čemu se sabira svaki pojedinačni pokušaj, a ne medijana. Mac mini je svih svojih 32 pokušaja (8 jednokratnih i 24 agentna) završio za 2.467,85 s (41 min 7,85 s). MacBook Pro je za svoja 32 pokušaja utrošio 10.437,0 s (2 h 53 min 57 s), pri čemu najveći deo zauizima model DeepSeek-R1 sa rezonovanjem. Svih 64 pokušaja (16 jednokratnih i 48 agentnih) traju ukupno 12.904,85 s (3 h 35 min 4,85 s).

Model	jednokr. asoc.	jednokr. kom.	ag. asoc. (med. od 3)	ag. kom. (med. od 3)
Gemma 3 4B	4,5	2,8	27	17
Gemma 3 12B	24,2	4,8	43	63
GLM-4 9B	14,7	2,3	106	49
GLM-4.7-Flash	55,0	30,4	216	212
Qwen2.5-Coder 14B	5,4	1,6	13	16
Qwen3	24,3	40,7	420	521
DeepSeek-Coder-V2 16B	5,8	0,5	51	49
DeepSeek-R1 8B	25,0	737,7	256	2.051

Tabela 1: Trajanja generisanja po modelu i teoremi, u sekundama. Agentne vrednosti su medijane tri pokušaja.

Mašina	Jednokratno	Agentno	Ukupno
Mac mini (Gemma/GLM)	138,85 s = 2 min 18,85 s (8 pokušaja)	2.329 s = 38 min 49 s (24 pokušaja)	2.467,85 s = 41 min 7,85 s
MacBook Pro (Qwen/DeepSeek)	841,0 s = 14 min 1 s (8 pokušaja)	9.596 s = 2 h 39 min 56 s (24 pokušaja)	10.437,0 s = 2 h 53 min 57 s
Ukupno	979,85 s = 16 min 19,85 s (16 pokušaja)	11.925 s = 3 h 18 min 45 s (48 pokušaja)	12.904,85 s = 3 h 35 min 4,85 s

Tabela 2: Ukupno vreme generisanja, sabrano po svakom pokušaju. Od agentnog vremena na MacBook Pro računaru 5.913 s (98 min 33 s) otpada samo na DeepSeek-R1 za komutativnost (pokušaji od 2.051 s, 1.712 s i 2.150 s), pri čemu su sva tri pokušaja neuspešna; isti model i jednokratno na komutativnosti troši 737,7 s.

3 Zaključak

1. Jednokratno se uspešno kompajlira 7 od 16 dokaza (43,75 %): asocijativnost 4/8, komutativnost 3/8. Komutativnost ostaje teža teorema.
2. Strategija nadjačava veličinu. Svaki uspešan dokaz je jednoredna primena gotove leme iz biblioteke (`rw [Nat.add_assoc]`, `exact Nat.add_comm a b`), dok nijedna indukcija ispočetka nije uspešno kompajlirana. GLM-4 od 9,4B nadmašuje Gemma-u 3 od 12,2B, a Gemma 3 od 4,3B i od 12,2B postižu jednak, nulti jednokratni učinak. Broj parametara, dakle, ne predviđa uspeh.
3. GLM-4.7-Flash ostvaruje maksimalan učinak u oba protokola. Reč je o mešavini eksperata od 29,9B parametara (približno 3B aktivnih po tokenu) [11] i jedinom modelu sa režimom rezonovanja („thinking“). Jednokratno rešava 2/2, agentno 6/6 pokušaja, uvek u prvoj rundi, uz medijanu trajanja od 216 s za asocijativnost i 212 s za komutativnost po agentnom pokušaju.
4. Agentna petlja izraženo pomaže modelima za kod. Na Qwen i DeepSeek modelima petlja često uspeva tamo gde jednokratni protokol ne uspe: DeepSeek-R1 jednokratno ne rešava asocijativnost, a agentno je rešava 3/3 (posle greške kompajlera pronalazi `rw [Nat.add_assoc]`); Qwen2.5-Coder agentno dobija komutativnost (1/3) i učvršćuje asocijativnost (2/3). Na Gemma i GLM modelima petlja gotovo ništa ne menja.
5. Rezonovanje je skupo i nije garancija uspeha. DeepSeek-R1 na komutativnosti troši 2.051 s, 1.712 s i 2.150 s po agentnom pokušaju (ukupno 5.913 s) i sva tri pokušaja su neuspešna; rezonovanje bez znanja prave leme samo produžava lutanje.
6. Verifikacija je pouzdana, ali i nju treba proveravati. Podrazumevano ograničenje tipske provere alata Ulam AI od 60 s lažno je obaralo ispravne dokaze pod pritiskom memorije, pa je u svim merenjima podignuto na 300 s.

3.1 Najčešći uzroci neuspeha

- Lean 3 sintaksa: blokovi `begin ...end`, zapete na kraju taktika, mala slova `nat.*`; Qwen2.5-Coder na komutativnosti piše `begin rw [add_comm], end`. Model je učio na kodu povučene verzije jezika.
- Neispravna Lean 4 `induction`: vitičaste zagrade umesto strelica u granama (`| zero { ...}` umesto `| zero => ...`), ili nedostaje induktivni korak.
- Halucinirano stanje dokaza: `rw ...at lhs` po hipotezi koja ne postoji, `cases goal`, pozivanje na neuvedena imena `this` i `ih`, izmišljene leme (`Nat.addition_assoc`).
- Nezavršeni ciljevi: niz taktika ne zatvori cilj.

Literatura

[1] L. de Moura, S. Ullrich, *The Lean 4 Theorem Prover and Programming Language*, CADE-28, 2021.

[2] The mathlib Community, *The Lean Mathematical Library*, CPP, 2020.

[3] Ollama, *Ollama: Get up and running with large language models locally*, dokumentacija projekta, https://ollama.com.

[4] Ulam AI, *Ulam AI: Truth-first Lean 4 theorem prover CLI* (verzija 0.2.11), dokumentacija projekta, 2026.

[5] K. Yang i dr., *LeanDojo: Theorem Proving with Retrieval-Augmented Language Models*, NeurIPS, 2023.

[6] K. Zheng, J. M. Han, S. Polu, *miniF2F: a cross-system benchmark for formal Olympiad-level mathematics*, ICLR, 2022.

[7] Z. Shao i dr., *DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models* (uvodi GRPO), 2024.

[8] DeepSeek-AI, *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*, 2025.

[9] N. Lambert i dr., *Tülü 3: Pushing Frontiers in Open Language Model Post-Training*, 2024.

[10] Gemma tim, Google DeepMind, *Gemma 3 Technical Report*, arXiv:2503.19786, 2025.

[11] GLM tim, Zhipu AI, *ChatGLM: A Family of Large Language Models from GLM-130B to GLM-4 All Tools*, arXiv:2406.12793, 2024.

[12] Ulam AI, *RAVE: Router-Aware Virtual Experts, One-shot MoE compression via shared centroids and low-rank residuals*, istraživački izveštaj, 2026.